

RAFAEL RANGEL DOS SANTOS FARINHA

Engenheiro de Inteligência Artificial

AI Engineer · RAG · Multiagente · System prompt · Economia de tokens · Evals · Escala

Rio de Janeiro – RJ · (21) 92036-1740 · stackflow.soft@gmail.com

github.com/Rafael-Rangel · rafael-rangel.github.io/portfolio

RESUMO

Engenheiro de IA e software: construo pipelines de LLM e RAG com embeddings, hybrid search, BM25, rerank, grounding, citações e knowledge base. Orquestro sistemas multiagente (planner/executor) com tool calling, function calling, system prompt, context engineering, prompt caching, token budget, economia de tokens, model routing e streaming, e meço precisão com evals, faithfulness, hallucination control, LLM-as-judge e human-in-the-loop. Entrego isso em SaaS multi-tenant de CRM omnichannel (WhatsApp Cloud API, Instagram, Meta), com webhooks, APIs REST, filas, escala horizontal, load balancing, isolamento de tenant, ACL, RBAC, pgvector e PostgreSQL — stack TypeScript, Python, React, Next.js, Node.js, NestJS, Docker, AWS, Azure, LLMOps, guardrails, PII e prompt injection.

EXPERIÊNCIA PROFISSIONAL

Jul 2025 – Atual

Diretor do Departamento de Software & Software Engineer

SaaS · Rio de Janeiro, RJ

- Dirigi a engenharia de IA em CRM e atendimento: orquestração multiagente, tool calling, planner/executor e human-in-the-loop.
- Implementei RAG ponta a ponta: ingestão, chunking, embeddings, hybrid search, rerank, grounding, citações e fidelidade da resposta.
- Otimizei economia de tokens: system prompt, context engineering, prompt caching, compressão de contexto, model routing e budget de tokens.
- Aumentei precisão de agentes com evals (tool-call accuracy, faithfulness, regressão de prompts) e fallback quando o retrieval falha.
- Escalei inferência e filas por tenant: isolamento de contexto, ACL na knowledge base, streaming, retries e observabilidade LLMOps.

Jul 2024 – Jul 2025

Desenvolvedor Front-end

Web · Rio de Janeiro, RJ

- Produzi e-commerce com +5.000 produtos, cadastro de catálogo, integração ao Bling, PDV em 3 lojas e estoque 100% sincronizado com fábrica.
- Desenvolvi sistema de delivery com gateway de pagamento, split Pagar.me, cálculo de frete e integração aos Correios.

PROJETOS EM DESTAQUE

KoruVision CRM — github.com/Rafael-Rangel/koruvision-landing

SaaS de CRM com agentes de IA, Workflows, RAG e atendimento omnichannel (WhatsApp/Instagram).

Rubi 2.0 / Conversation AI — github.com/Rafael-Rangel/rubi-teste

Agentes especializados, knowledge base, evals de precisão e handoff para humano.

Inglês conversacional para Devs — github.com/Rafael-Rangel/ingles-conversacional-devs

Tutor com embeddings, context window controlada e prática de system/user prompt.

FORMAÇÃO

Análise e Desenvolvimento de Sistemas — FIAP. Conclusão em 2025 (2 anos).

CERTIFICADOS

- Certificado de Qualificação Profissional em Estratégia e Inovação Tecnológica com aplicações em IA e IoT (2025)
- Certificado de Qualificação Profissional em Desenvolvimento de Aplicações Móveis (2025)
- Certificado de Qualificação Profissional em Análise e Design Web 2.0 (2024)
- Certificado de Qualificação Profissional em Análise de Sistemas e Prototipação Web (2024)
- Certificado de Qualificação Profissional em Análise de Sistemas e Prototipagem Web (2024)
- Certificado de Qualificação Profissional em Desenvolvimento e Designer Web 2.0 (2024)

COMPETÊNCIAS TÉCNICAS

- IA: RAG, embeddings, hybrid search, rerank, multi-agent, tool calling, function calling, system prompt, context engineering, evals

- **Tokens e qualidade:** token budget, prompt caching, model routing, streaming, faithfulness, hallucination control, LLM-as-judge
- **Escala e cloud:** filas, pgvector, PostgreSQL, tenant ACL, LLMOps, Python, TypeScript, OpenAI, Node.js, NestJS, AWS, Azure, Docker, guardrails, PII, prompt injection