

RAFAEL RANGEL DOS SANTOS FARINHA

Engenheiro de Inteligência Artificial

AI Engineer · RAG · Multiagente · System prompt · Economia de tokens · Evals · Escala

Rio de Janeiro – RJ · (21) 92036-1740 · stackflow.soft@gmail.com

github.com/Rafael-Rangel · rafael-rangel.github.io/portfolio

RESUMO

Projeto e coloco em produção sistemas de LLM: RAG, embeddings, multiagentes, system prompts e knowledge base. Otimizo economia de tokens, precisão de tool calling e escala de inferência em SaaS multi-tenant (CRM, WhatsApp, APIs). Atuo na Genesis Company como Diretor do Departamento de Software e Software Engineer.

EXPERIÊNCIA PROFISSIONAL

Jul 2025 – Atual	Diretor do Departamento de Software & Software Engineer Genesis Company · Rio de Janeiro, RJ • Dirigi a engenharia de IA em CRM e atendimento: orquestração multiagente, tool calling, planner/executor e human-in-the-loop. • Implementei RAG ponta a ponta: ingestão, chunking, embeddings, hybrid search, rerank, grounding, citações e fidelidade da resposta. • Otimizei economia de tokens: system prompt, context engineering, prompt caching, compressão de contexto, model routing e budget de tokens. • Aumentei precisão de agentes com evals (tool-call accuracy, faithfulness, regressão de prompts) e fallback quando o retrieval falha. • Escalei inferência e filas por tenant: isolamento de contexto, ACL na knowledge base, streaming, retries e observabilidade LLMOps.
Jul 2024 – Jul 2025	Web Developer / Software Developer Webmaker · Rio de Janeiro, RJ • Desenvolvi aplicações e APIs que passaram a alimentar pipelines de RAG e agentes.

PROJETOS EM DESTAQUE

- KoruVision CRM** — github.com/Rafael-Rangel/koruvision-landing
SaaS multi-tenant com RAG, multiagentes, system prompts e canais WhatsApp/Instagram em escala.
- Rubi 2.0 / Conversation AI** — github.com/Rafael-Rangel/rubi-teste
Agentes especializados, knowledge base, evals de precisão e handoff para humano.
- Inglês conversacional para Devs** — github.com/Rafael-Rangel/ingles-conversacional-devs
Tutor com embeddings, context window controlada e prática de system/user prompt.

FORMAÇÃO

Análise e Desenvolvimento de Sistemas — FIAP. Conclusão em 2025 (2 anos).

CERTIFICADOS

- Certificado de Qualificação Profissional em Estratégia e Inovação Tecnológica com aplicações em IA e IoT (2025)
- Certificado de Qualificação Profissional em Desenvolvimento de Aplicações Móveis (2025)
- Certificado de Qualificação Profissional em Análise e Design Web 2.0 (2024)
- Certificado de Qualificação Profissional em Análise de Sistemas e Prototipação Web (2024)
- Certificado de Qualificação Profissional em Análise de Sistemas e Prototipagem Web (2024)
- Certificado de Qualificação Profissional em Desenvolvimento e Designer Web 2.0 (2024)

COMPETÊNCIAS TÉCNICAS

- **IA:** RAG, embeddings, hybrid search, rerank, multi-agent, tool calling, function calling, system prompt, context engineering, evals
- **Tokens e qualidade:** token budget, prompt caching, model routing, streaming, faithfulness, hallucination control, LLM-as-judge
- **Escala:** filas, processamento assíncrono, pgvector, PostgreSQL, isolamento de tenant, ACL, observabilidade LLMOps
- **Stack e cloud:** Python, TypeScript, OpenAI, Node.js, NestJS, AWS, Azure, Docker, guardrails, PII, prompt injection