

RAFAEL RANGEL DOS SANTOS FARINHA

Engenheiro de Inteligência Artificial

AI Engineer · RAG · Multiagente · System prompt · Economia de tokens · Evals · Escala

Rio de Janeiro – RJ · (21) 92036-1740 · stackflow.soft@gmail.com

github.com/Rafael-Rangel · rafael-rangel.github.io/portfolio

RESUMO

Engenheiro de IA e software: LLM, RAG, embeddings, hybrid search, BM25, rerank, grounding, citações, knowledge base, multiagente, orquestração, planner/executor, tool calling, function calling, system prompt, context engineering, prompt caching, token budget, economia de tokens, model routing, streaming, evals, faithfulness, hallucination control, LLM-as-judge, human-in-the-loop, precisão de agentes. SaaS multi-tenant, CRM, omnichannel, WhatsApp Cloud API, Instagram, Meta, webhooks, APIs REST, filas, escala horizontal, load balancing, isolamento de tenant, ACL, RBAC, pgvector, PostgreSQL, TypeScript, Python, React, Next.js, Node.js, NestJS, Docker, AWS, Azure, LLMOps, guardrails, PII, prompt injection.

EXPERIÊNCIA PROFISSIONAL

Jul 2025 – Atual	Diretor do Departamento de Software & Software Engineer SaaS · Rio de Janeiro, RJ • Dirigi a engenharia de IA em CRM e atendimento: orquestração multiagente, tool calling, planner/executor e human-in-the-loop. • Implementei RAG ponta a ponta: ingestão, chunking, embeddings, hybrid search, rerank, grounding, citações e fidelidade da resposta. • Otimizei economia de tokens: system prompt, context engineering, prompt caching, compressão de contexto, model routing e budget de tokens. • Aumentei precisão de agentes com evals (tool-call accuracy, faithfulness, regressão de prompts) e fallback quando o retrieval falha. • Escalei inferência e filas por tenant: isolamento de contexto, ACL na knowledge base, streaming, retries e observabilidade LLMOps.
Jul 2024 – Jul 2025	Web Developer / Software Developer Web · Rio de Janeiro, RJ • Desenvolvi aplicações e APIs que passaram a alimentar pipelines de RAG e agentes.

PROJETOS EM DESTAQUE

KoruVision CRM — github.com/Rafael-Rangel/koruvision-landing

SaaS multi-tenant com RAG, multiagentes, system prompts e canais WhatsApp/Instagram em escala.

Rubi 2.0 / Conversation AI — github.com/Rafael-Rangel/rubi-teste

Agentes especializados, knowledge base, evals de precisão e handoff para humano.

Inglês conversacional para Devs — github.com/Rafael-Rangel/ingles-conversacional-devs

Tutor com embeddings, context window controlada e prática de system/user prompt.

FORMAÇÃO

Análise e Desenvolvimento de Sistemas — FIAP. Conclusão em 2025 (2 anos).

CERTIFICADOS

- Certificado de Qualificação Profissional em Estratégia e Inovação Tecnológica com aplicações em IA e IoT (2025)
- Certificado de Qualificação Profissional em Desenvolvimento de Aplicações Móveis (2025)
- Certificado de Qualificação Profissional em Análise e Design Web 2.0 (2024)
- Certificado de Qualificação Profissional em Análise de Sistemas e Prototipação Web (2024)
- Certificado de Qualificação Profissional em Análise de Sistemas e Prototipagem Web (2024)
- Certificado de Qualificação Profissional em Desenvolvimento e Designer Web 2.0 (2024)

COMPETÊNCIAS TÉCNICAS

- **IA:** RAG, embeddings, hybrid search, rerank, multi-agent, tool calling, function calling, system prompt, context engineering, evals
- **Tokens e qualidade:** token budget, prompt caching, model routing, streaming, faithfulness, hallucination control, LLM-as-judge
- **Escala e cloud:** filas, pgvector, PostgreSQL, tenant ACL, LLMOps, Python, TypeScript, OpenAI, Node.js, NestJS,

AWS, Azure, Docker, guardrails, PII, prompt injection