

RAFAEL RANGEL DOS SANTOS FARINHA

Engenheiro de Inteligência Artificial

AI Engineer · RAG · Multiagente · System prompt · Economia de tokens · Evals · Escala

Rio de Janeiro – RJ · (21) 92036-1740 · stackflow.soft@gmail.com

github.com/Rafael-Rangel · rafa-el-rangel.github.io/portfolio

RESUMO

Engenheiro de IA e software: construo pipelines de LLM e RAG com embeddings, hybrid search, BM25, rerank, grounding, citações e knowledge base. Orquestro multiagente (planner/executor) com tool calling, function calling, system prompt, context engineering, prompt caching, token budget, economia de tokens, model routing e streaming; meço precisão com evals, faithfulness, hallucination control, LLM-as-judge e human-in-the-loop. Entrego em SaaS multi-tenant de CRM omnichannel (WhatsApp Cloud API, Instagram, Meta), com webhooks, APIs REST, filas, escala horizontal, load balancing, isolamento de tenant, ACL, RBAC, pgvector, PostgreSQL, TypeScript, Python, React, Next.js, Node.js, NestJS, Docker, AWS, Azure, LLMOps, guardrails, PII e prompt injection.

EXPERIÊNCIA PROFISSIONAL

Jul 2025 – Atual	Diretor do Departamento de Software & Software Engineer SaaS · Rio de Janeiro, RJ • Dirigi a engenharia de IA em CRM e atendimento: orquestração multiagente, tool calling, planner/executor e human-in-the-loop. • Implementei RAG ponta a ponta: ingestão, chunking, embeddings, hybrid search, rerank, grounding, citações e fidelidade da resposta. • Otimizei economia de tokens: system prompt, context engineering, prompt caching, compressão de contexto, model routing e budget de tokens. • Aumentei precisão de agentes com evals (tool-call accuracy, faithfulness, regressão de prompts) e fallback quando o retrieval falha. • Escalei inferência e filas por tenant: isolamento de contexto, ACL na knowledge base, streaming, retries e observabilidade LLMOps.
Jul 2024 – Jul 2025	Desenvolvedor Front-end Web · Rio de Janeiro, RJ • Produzi e-commerce com +5.000 produtos, cadastro de catálogo, integração ao Bling, PDV em 3 lojas e estoque 100% sincronizado com fábrica. • Desenvolvi sistema de delivery com gateway de pagamento, split Pagar.me, cálculo de frete e integração aos Correios.

PROJETOS EM DESTAQUE

KoruVision CRM — github.com/Rafael-Rangel/koruvision-landing

SaaS de CRM com agentes de IA, Workflows, RAG e atendimento omnichannel (WhatsApp/Instagram).

Icare Finance — sistem-ifood.vercel.app

Painel de gestão para restaurante: pedidos, pagamentos, repasses iFood, cardápio, relatórios e permissões.

FORMAÇÃO

Análise e Desenvolvimento de Sistemas — FIAP. Conclusão em 2025 (2 anos).

CERTIFICADOS

- Certificado de Qualificação Profissional em Estratégia e Inovação Tecnológica com aplicações em IA e IoT (2025)
- Certificado de Qualificação Profissional em Desenvolvimento de Aplicações Móveis (2025)
- Certificado de Qualificação Profissional em Análise e Design Web 2.0 (2024)
- Certificado de Qualificação Profissional em Análise de Sistemas e Prototipação Web (2024)
- Certificado de Qualificação Profissional em Análise de Sistemas e Prototipagem Web (2024)
- Certificado de Qualificação Profissional em Desenvolvimento e Designer Web 2.0 (2024)

COMPETÊNCIAS TÉCNICAS

- **IA:** RAG, embeddings, hybrid search, rerank, multi-agent, tool calling, function calling, system prompt, context engineering, evals
- **Tokens e qualidade:** token budget, prompt caching, model routing, streaming, faithfulness, hallucination control, LLM-as-judge
- **Escala e cloud:** filas, pgvector, PostgreSQL, tenant ACL, LLMOps, Python, TypeScript, OpenAI, Node.js, NestJS,

AWS, Azure, Docker, guardrails, PII, prompt injection